

Card26_Modelos_Generativos

Davi Bezerra Barros

Variational Auto-Encoders

Auto Encoders: Geralmente utilizados para compressão de imagens, remoção de ruídos e geração de dados, os autoencoders são compostos por duas partes; o Encoder, que recebe uma imagem como input e a mapeia para um espaço dimensional inferior chamado de espaço latente, e o decoder, que reconstrói a imagem original a partir desta representação espacial. Eles podem aprender a capturar as características de uma imagem enquanto descartam o ruído. Os autoencoders podem ser treinados sem supervisão e representam dados com alta dimensionalidade, e assim reduzem o espaço de armazenamento utilizado pelo dataset ao comprimir as imagens;

Variational Auto Encoders: Ao contrário dos auto-encoders clássicos, que mapeiam um dado de entrada para um ponto no espaço latente, os auto-encoders variacionais mapeiam os dados para uma distribuição probabilística em dois vetores no espaço latente; um de médias e um de desvio padrão.

General Adversarial Networks:

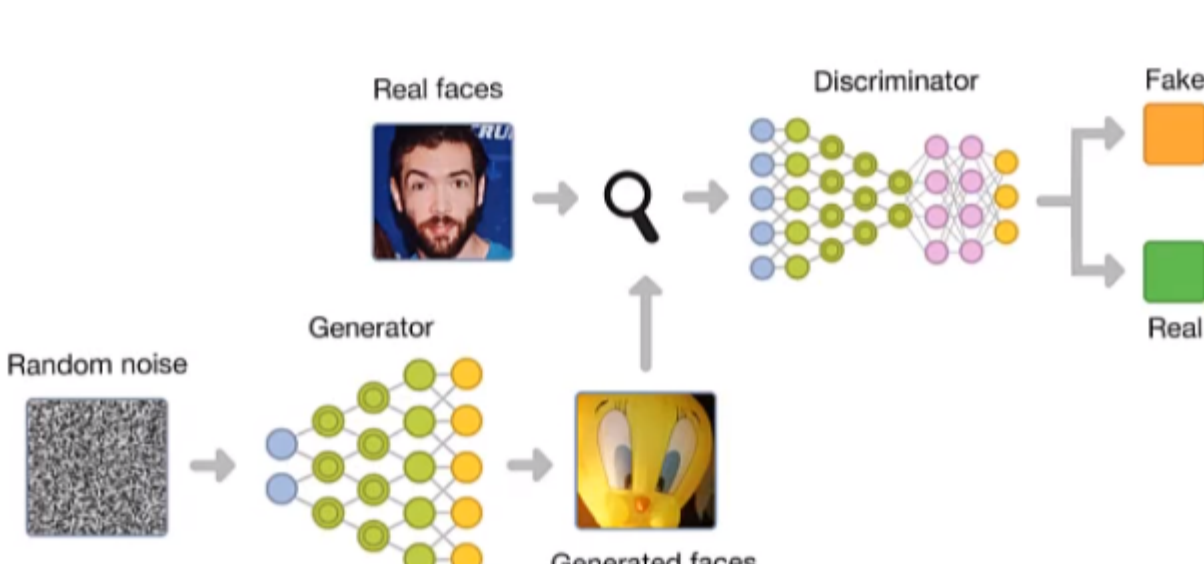
São redes neurais generativas utilizadas para criar datasets sintéticos que se assemelham a dados reais, para diferentes aplicações.

Funcionamento:

As GAN's são compostas por dois componentes principais:

Gerador: Componente responsável por criar dados falsos a partir de um vetor de ruído. Seu objetivo é criar imagens que são indistinguíveis das imagens reais.

Discriminador: Recebe os dados reais e os dados falsos gerados pelo gerador, e tenta distinguir qual é o falso. O objetivo do discriminador é identificar quais imagens são falsas, e melhorar sua capacidade de detecção ao longo das épocas de treinamento.



Ao longo do treinamento, tanto o gerador quanto o discriminador tentam melhorar suas capacidades e competem entre si, como adversários. O gerador tenta criar imagens cada vez melhores para enganar o discriminador, e o discriminador tenta avaliar com mais exatidão a cada época. O treinamento acaba quando o discriminador não é mais capaz de distinguir entre as imagens falsas e reais.

Construindo o Mini-GPT

Transformers

O vídeo apresentado por Andrej Karpathy -co-fundador da Open-AI- ensina a construir o modelo mais básico do ChatGPT a partir do artigo "Attention is all you need", publicado por pesquisadores da Google. O artigo introduz o *transformer*, uma arquitetura proposta para processamento de linguagem natural(NLP) que se baseia em um mecanismo chamado *self-attention*.

Self-Attention

O Self-Attention ou "Auto-atenção", relaciona diferentes posições de uma única sequência para computar uma representação da sequência, permitindo encontrar correlações entre as palavras de entrada e sua estrutura sintática, em modelos *Sequence to Sequence*.

- **Sequence-to-Sequence:** Um modelo que recebe uma sequencia de itens(palavras, letras, tokens etc) e devolve outra sequência de itens.

A autoatenção permite que cada token de entrada troque informações com todos os outros tokens da mesma sequência, independentemente de sua posição. Isso permite que o modelo capture relações semânticas complexas entre os tokens, superando as limitações que as *RNN's* tem devido ao tamanho da janela de contexto. Além disso, a autoatenção permite o processamento de todos os tokens em paralelo, o que acelera o treinamento.

Implementando o mini-gpt

O modelo desenvolvido no tutorial foi implementado com a biblioteca **PyTorch**, e treinado com o texto Tiny-Shakespeare. Ele foi definido como uma sequência de blocos de atenção seguidos por camadas lineares, fazendo as etapas:

1. Codifica os tokens em vetores de embedding.
2. Adiciona embeddings posicionais, que informam a posição dos tokens na sequência.
3. Passa pelos blocos Transformer, aplicando autoatenção e camadas FeedForward.
4. Retorna as previsões para o próximo caractere (usadas para calcular a perda com *cross_entropy*).

O modelo é treinado por meio de iterações, onde para cada iteração:

1. Um lote de dados é obtido.
2. O modelo faz previsões e a perda é calculada.
3. O otimizador ajusta os pesos do modelo com base no gradiente da perda.

Conclusão

As atividades desta etapa abordaram conceitos importantes do estado da arte das redes neurais generativas, como os **Variational Auto-Encoders** (VAEs) e as **Generative Adversarial Networks** (GANs), explorando como esses modelos geram dados realistas.

A implementação do **mini-GPT** utilizando **Transformers** introduziu o conteito de **self-attention** e sua capacidade em capturar relações complexas em sequências de texto, superando limitações de modelos anteriores. Os conhecimentos adquiridos são essenciais para o desenvolvimento de redes neurais mais avançadas e eficientes.